

# Линеен регресионен модел. Метод на най-малките квадрати. Теорема на Гаус-Марков.

П.Матеев

София, 2012

Формулира се задачата и модела на линейна регресия в общия случай или в случая с проста линейна регресия. Показва се, че при нормално разпределение на грешките в модела, максимално правдоподобните оценки съвпадат с решението на нормалната система уравнения от „метод на най-малките квадрати“. Показва се неизместеност и се извежда дисперсията на оценките.

Доказва се теоремата на Гаус – Марков, че оценката на параметрите, получени като решение на нормалната система уравнения са с минимална дисперсия (относно всички неизместени оценки).

## Съдържание

<b>1</b>	<b>Линеен регресионен модел.</b>	<b>2</b>
1.1	Регресионен експеримент. . . . .	2
1.2	Регресионен модел. . . . .	2
1.3	Линеен регресионен модел. . . . .	2
<b>2</b>	<b>Метод на най-малките квадрати.</b>	<b>3</b>
2.1	Данни от регресионен експеримент. . . . .	3
2.2	Метод на най-малките квадрати. . . . .	3
2.3	Нормално разпределение на грешките. . . . .	5
<b>3</b>	<b>Теорема на Гаус-Марков</b>	<b>5</b>
3.1	Твърдение . . . . .	5
3.2	Доказателство . . . . .	6
3.3	Коментар . . . . .	6

# 1 Линеен регресионен модел.

## 1.1 Регресионен експеримент.

Данните от проведено изследване или експеримент са наблюдения на

- отклик  $y$  и
- предиктори  $\mathbf{x} = (x(1), x(2), \dots, x(m))'$ .

Предикторите описват условията, при които се провежда отделно наблюдение. Задачата е да предсказваме резултата от наблюдение на количествена променлива, наричана отклик, при известни условия на наблюдение. С други думи да установим зависимост на отклика от конкретните стойности на предикторите.

## 1.2 Регресионен модел.

*Регресионен модел* наричаме случайна величина  $Y$ , чието разпределение зависи от предикторите, съответства на променливата отклик и удовлетворява условията:

- $\mathbb{E}(Y | \mathbf{x}) = f(\mathbf{x})$  - математическото очакване на  $Y$  е функция на предикторите,  $f(\mathbf{x})$  наричаме *регресионна функция*;
- $\text{Var } Y = \sigma^2$  - дисперсията на  $Y$  е константа (не зависи от  $\mathbf{x}$ ).

Разликата  $e = Y - f(\mathbf{x})$  е случайна величина и се интерпретира като *случайна грешка* при наблюдаване на отклика, чиято “истинска” стойност е  $f(\mathbf{x})$ . Разпределението на грешката е с очакване  $\mathbb{E}e = 0$  и дисперсия  $\text{Var } e = \sigma^2$ .

Регресионният модел се представя чрез *регресионно уравнение*

$$Y = f(\mathbf{x}) + e, \quad (\mathbb{E}e = 0, \quad \text{Var } e = \sigma^2).$$

## 1.3 Линеен регресионен модел.

Регресионен модел е *линеен*, когато функцията  $f(\mathbf{x})$  е зададена с точност до неизвестен параметър  $\mathbf{b}' = (b_1, \dots, b_p)$  и зависи от този параметър линейно

$$f(\mathbf{x}) = b_1 f_1(\mathbf{x}) + \dots + b_p f_p(\mathbf{x}) = \sum_{j=1}^p b_j f_j(\mathbf{x}).$$

Без загуба на общност, можем да считаме, че условията се описват от  $f_j(\mathbf{x})$  или нови променливи, получени чрез трансформация на оригиналните предиктори. За краткост пишем,

$$f(\mathbf{x}) = b_1 x(1) + \dots + b_p x(p) = \sum_{j=1}^p x(j) b_j = \mathbf{x}' \mathbf{b}.$$

*Линеен регресионен модел* се представя чрез линейно регресионно уравнение

$$Y = b_1 x(1) + \dots + b_p x(p) + e, \quad (\mathbb{E}e = 0, \quad \text{Var } e = \sigma^2),$$

линейно спрямо неизвестните параметри  $b_j$ !

## 2 Метод на най-малките квадрати.

### 2.1 Данни от регресионен експеримент.

Нека регресионен експеримент е проведен  $n$  пъти при различни условия  $\mathbf{x}_i = (x_i(1), \dots, x_i(p))'$ ,  $i = 1, \dots, n$ , и наблюдаваните стойности на отклика са били  $y_i$ ,  $i = 1, \dots, n$ .

Наблюденията удовлетворяват  $n$  регресионни уравнения

$$y_i = b_1 x_i(1) + \dots + b_p x_i(p) + e_i, \quad i = 1, \dots, n.$$

Данните записваме в матричен вид, като наблюденията на всяка променлива е  $n$ -мерен вектор

- $\mathbf{y} = (y_1, \dots, y_n)'$  са наблюденията на отклика, а
- $\mathbf{x}(j) = (x_1(j), \dots, x_n(j))'$  са наблюденията на  $j$ -тия от предикторите ( $j = 1, \dots, p$ ).

*Матрица на експеримента* наричаме матрицата, чиито стълбове са наблюденията на  $p$ -те предиктора, а редовете са транспонирани векторите на условията на наблюдение  $\mathbf{x}_i' = (x_i(1), \dots, x_i(p))$  ( $i = 1, \dots, n$ ) :

$$\mathbf{X}_{(n \times p)} = \begin{pmatrix} \mathbf{x}(1) & \dots & \mathbf{x}(p) \end{pmatrix} = \begin{pmatrix} \mathbf{x}'_1 \\ \dots \\ \mathbf{x}'_n \end{pmatrix}.$$

Регресионните уравнения за  $n$ -те наблюдения в матричен запис са:

$$\mathbf{y}_{(n \times 1)} = \mathbf{X}_{(n \times p)} \cdot \mathbf{b}_{(p \times 1)} + \mathbf{e}_{(n \times 1)} \quad \text{или накратко} \quad \mathbf{y} = \mathbf{X}\mathbf{b} + \mathbf{e}.$$

Сега  $e_i$  е неизвестната “грешка” при  $i$ -тото наблюдение и  $\mathbf{e}' = (e_1, e_2, \dots, e_n)$ .

В системата от  $n$  уравнения неизвестните са  $p + n$  на брой – параметрите  $\mathbf{b}$  и грешките  $\mathbf{e}$ .

Задачата е да оценим  $\mathbf{b}$  като наложим подходящи и разумни ограничения за грешките  $\mathbf{e}$ .

### 2.2 Метод на най-малките квадрати.

Карл Фридрих Гаус постулира *метод на най-малките квадрати* като определя условие за грешките

Неизвестните параметри се определят така,  
че сумата от квадратите на грешките да е минимална!

Разликите  $y_i - \sum_{j=1}^p x_i(j)b_j = e_i$ ,  $i = 1, \dots, n$ , наричаме още *остатъци (residuals)* и по традиция сумата от квадратите им (Sum of Squares) означаваме с

$$SS(\mathbf{b}) = \sum_{i=1}^n e_i^2 = \mathbf{e}'\mathbf{e}.$$

**Теорема 1** Ако  $\hat{\mathbf{b}}$  е решение на системата

$$\mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{X}'\mathbf{y},$$

наричана **системата от нормални уравнения**, то за  $\hat{\mathbf{b}}$  се достига минимума на сумата от квадрати  $SS(\mathbf{b})$ :

$$SS(\mathbf{b}) \geq SS(\hat{\mathbf{b}}).$$

*Забележка 1.* Нормалната система уравнения е друга форма на запис на условието за некорелираност на  $\mathbf{e}$  и  $\mathbf{x}(j)$ ,  $j = 1, \dots, p$ , т.е.

$$\mathbf{X}'\mathbf{e} = \mathbf{X}'(\mathbf{y} - \mathbf{X}\mathbf{b}) = \mathbf{X}'\mathbf{y} - \mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{0}.$$

*Забележка 2.* Нормалната система уравнения е еквивалентна на анулиране на първите производни на  $SS(\mathbf{b})$  по параметъра  $\mathbf{b}$ :

$$\begin{aligned} \frac{\partial SS}{\partial \mathbf{b}} &= \frac{\partial \mathbf{e}'\mathbf{e}}{\partial \mathbf{b}} = \frac{\partial (\mathbf{y} - \mathbf{X}\mathbf{b})'(\mathbf{y} - \mathbf{X}\mathbf{b})}{\partial \mathbf{b}} = \\ &= \frac{\partial (\mathbf{y}'\mathbf{y} - 2\mathbf{bX}'\mathbf{y} + \mathbf{b}'\mathbf{X}'\mathbf{X}\mathbf{b})}{\partial \mathbf{b}} = \\ &= -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\mathbf{b}. \end{aligned}$$

*Директно доказателство* следва от равенствата

$$\begin{aligned} SS(\mathbf{b}) &= (\mathbf{y} - \mathbf{X}\mathbf{b})'(\mathbf{y} - \mathbf{X}\mathbf{b}) = \\ &= (\mathbf{y} - \mathbf{X}\hat{\mathbf{b}} + \mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b})'(\mathbf{y} - \mathbf{X}\hat{\mathbf{b}} + \mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b}) = \\ &= (\mathbf{y} - \mathbf{X}\hat{\mathbf{b}})'(\mathbf{y} - \mathbf{X}\hat{\mathbf{b}}) + (\mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b})'(\mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b}) + \\ &\quad + 2(\mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b})'(\mathbf{y} - \mathbf{X}\hat{\mathbf{b}}) = \\ &= SS(\hat{\mathbf{b}}) + (\mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b})'(\mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b}), \end{aligned}$$

тъй като

$$(\mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b})'(\mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b}) \geq 0,$$

а

$$\begin{aligned} (\mathbf{X}\hat{\mathbf{b}} - \mathbf{X}\mathbf{b})'(\mathbf{y} - \mathbf{X}\hat{\mathbf{b}}) &= (\hat{\mathbf{b}} - \mathbf{b})'\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\mathbf{b}}) = \\ &= (\hat{\mathbf{b}} - \mathbf{b})'(\mathbf{X}'\mathbf{y} - \mathbf{X}'\mathbf{X}\hat{\mathbf{b}}) = 0. \end{aligned}$$

Нормалната система уравнения има единствено решение, ако ранга на  $\mathbf{X}$  е равен на  $p$ , т.е. стълбовете  $\mathbf{x}(\mathbf{j})$  са линейно независими. Решението на системата е търсената оценка:

$$\hat{\mathbf{b}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

Веднага можем да получим и оценки за математическите очаквания на отклика за всяко едно наблюдение  $\hat{\mathbf{y}} = \mathbf{X}\hat{\mathbf{b}}$ . Разликите между съответните наблюдавани стойности и оценките на средните са оценки за грешките на наблюдаените (на остатъците или residuals) при така избрания модел с така оценени параметри. Ще ги означим с  $r_i$ ,  $i = 1, \dots, n$  или

$$\mathbf{r} \stackrel{def}{=} \mathbf{y} - \hat{\mathbf{y}}.$$

Освен това

$$SS(\hat{\mathbf{b}}) = \mathbf{r}'\mathbf{r}.$$

## 2.3 Нормално разпределение на грешките.

Нека за грешките предположим, че са независими и нормално разпределени

$$e_i \sim N(0, \sigma^2), \quad i = 1, \dots, n, \quad \text{или } \mathbf{e} \sim \mathbf{N}(\mathbf{0}, \sigma^2 \mathbf{I}).$$

Тогава нормално е разпределението и на наблюденията  $\mathbf{y} \sim \mathbf{N}(\mathbf{X}\mathbf{b}, \sigma^2 \mathbf{I})$  и оценките, получени по МНК, съвпадат с оценките получени по метода на максималното правдоподобие и притежават всички техни оптимални свойства.

Системата има единствено решение, ако ранга на  $\mathbf{X}$  е равен на  $p$ , т.е. стълбовете  $\mathbf{x}(\mathbf{j})$  са линейно независими. Решението на системата е търсената оценка:

$$\hat{\mathbf{b}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

Веднага можем да получим и оценки за математическите очаквания на отклика за всяко едно наблюдение  $\hat{Y} = \mathbf{X}\hat{\mathbf{b}}$ . Разликите между съответните наблюдавани стойности и оценките на средните им наричаме *остатъци* (*Residuals*). Те са оценки за грешките на наблюденията при така избрания модел с така оценени параметри. Ще ги означим с  $r_i$ ,  $i = 1, \dots, n$  или

$$\begin{aligned} \mathbf{r} &\stackrel{\text{def}}{=} \mathbf{y} - \hat{\mathbf{y}} = \\ &= \mathbf{y} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{I} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')\mathbf{y}. \end{aligned}$$

## 3 Теорема на Гаус-Марков

### 3.1 Твърдение

**Теорема 2 (Гаус-Марков)** *Нека неизвестните грешки се подчиняват на условията:*

- $\mathbb{E} e_i = 0, \quad i = 1, \dots, n;$
- $\text{Var } e_i = \sigma^2 > 0, \quad i = 1, \dots, n;$
- $\text{cov}(e_i, e_j) = 0, \quad i \neq j.$

*и нека  $\hat{\mathbf{b}}$  е решение на системата нормални уравнения*

$$\mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{X}'\mathbf{y}.$$

*Тогава  $\hat{\mathbf{b}}$  е BLUE (Best Linear Unbiased Estimator):*

1. *линейна по случайния вектор  $\mathbf{y}$ :  $\hat{\mathbf{b}} = \mathbf{C}\mathbf{y}$  и*
2. *неизместена  $\mathbb{E} \hat{\mathbf{b}} = \mathbf{b}$ ,*
3. *с минимална дисперсия – за всяка друга линейна по  $\mathbf{y}$  неизместена оценка  $\tilde{\mathbf{b}}$  е изпълнено неравенство:*

$$\text{Var } \hat{\mathbf{b}} \leq \text{Var } \tilde{\mathbf{b}}.$$

Неравенството е в смисъл, че разликата на двете ковариационни матрици  $\mathbf{D} = \text{Var } \tilde{\mathbf{b}} - \text{Var } \hat{\mathbf{b}}$  е неотрицателно определена матрица:

$$\text{за } \forall \mathbf{x} \quad \mathbf{x}'\mathbf{D}\mathbf{x} \geq 0.$$

### 3.2 Доказателство

Последователно доказваме трите свойства на  $\hat{\mathbf{b}}$ :

1.  $\hat{\mathbf{b}}$  е линейна по вектора  $\mathbf{y}$

$$\hat{\mathbf{b}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{C}\mathbf{y} \text{ като } \mathbf{C} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}';$$

2.  $\hat{\mathbf{b}}$  е неизместена оценка на  $\mathbf{b}$

$$\mathbb{E} \hat{\mathbf{b}} = \mathbb{E} (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \mathbb{E} \mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{b};$$

3. с минимална дисперсия:

Дисперсията на  $\hat{\mathbf{b}}$  е

$$\begin{aligned} \text{Var } \hat{\mathbf{b}} &= \text{Var} (\mathbf{C}\mathbf{y}) = \mathbf{C}(\text{Var } \mathbf{y})\mathbf{C}' = \mathbf{C}\sigma^2\mathbf{I}_n\mathbf{C}' = \\ &= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}. \end{aligned}$$

Преди да изследваме дисперсията на  $\tilde{\mathbf{b}}$  ще означим  $\mathbf{U} = \mathbf{B} - \mathbf{C}$  и ще покажем, че  $\mathbf{U}\mathbf{X} = 0$ . Наистина  $\mathbb{E}(\mathbf{U}\mathbf{y}) = \mathbb{E}((\mathbf{B} - \mathbf{C})\mathbf{y}) = \mathbb{E}(\mathbf{B}\mathbf{y}) - \mathbb{E}(\mathbf{C}\mathbf{y}) = \mathbf{b} - \mathbf{b} = 0$ .

Освен това  $\mathbb{E}(\mathbf{U}\mathbf{y}) = \mathbf{U}\mathbb{E}\mathbf{y} = \mathbf{U}\mathbf{X}\mathbf{b}$ . Следователно  $\mathbf{U}\mathbf{X}\mathbf{b} = 0$  за произволни стойности на параметрите  $\mathbf{b}$ , което е възможно само при  $\mathbf{U}\mathbf{X} = 0$ . В следващото равенство използваме, че  $\mathbf{U}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \mathbf{U}\mathbf{C}' = 0$  и също  $\mathbf{C}\mathbf{U}' = 0$ .

$$\begin{aligned} \text{Var } \tilde{\mathbf{b}} &= \text{Var} (\mathbf{B}\mathbf{y}) = \mathbf{B}(\text{Var } \mathbf{y})\mathbf{B}' = \mathbf{B}(\sigma^2\mathbf{I}_n)\mathbf{B}' = \\ &= \sigma^2(\mathbf{C} + \mathbf{U})(\mathbf{C} + \mathbf{U})' = \sigma^2(\mathbf{C}\mathbf{C}' + \mathbf{U}\mathbf{C}' + \mathbf{C}\mathbf{U}' + \mathbf{U}\mathbf{U}') = \\ &= \text{Var } \hat{\mathbf{b}} + \sigma^2\mathbf{U}\mathbf{U}'. \end{aligned}$$

С което теоремата е доказана, защото  $\mathbf{U}\mathbf{U}' = 0$  е неотрицателно определена матрица.

### 3.3 Коментар

*Забележка 1.* Теоремата е в сила дори когато матрицата  $\mathbf{X}'\mathbf{X}$  е изродена и не съществува единствена обратна матрица  $(\mathbf{X}'\mathbf{X})^{-1}$ . Тогава в стъпките на доказателството вместо обратна матрица замества обобщена обратна матрица.

*Забележка 2.* При предположение за нормално разпределение на отклика и съответно на грешките, оценките, решение на нормалната система  $\hat{\mathbf{b}}$  съвпадат с оценки получени по метода на максималното правдоподобие, достигат равенство в *Неравенството на Рао-Крамер* и следователно са *ефективни*, дисперсията им е долна граница не само за линейните, а за всички неизместени оценки.